

压力测试 B-FAIS：面向时间序列基础模型的 预测感知块级填补器选择

摘要

预训练时间序列预测器要求输入有限数值上下文，因此缺失值填补构成预测流程的一部分。分块式预测感知填补器选择方法（Block-wise Forecast-Aware Imputer Selection, B-FAIS）针对每个极大连续缺失区间分配填补器，其依据包括下游预测损失、伪缺失证据、稀疏缺失块关系图和受候选有效性约束的搜索。本研究检验这些附加机制能否带来可测量的收益。实验预注册六项比较，在 16 个非 ETT 数据族的 26 个数据集版本上构造互不重叠的训练掩码与确认性掩码，每个预测器包含 2,340 个配对 episode，并保留 5 个路由器随机种子、5,000 次分层重采样区间和 Holm 多重校正。预测监督相对于重建监督的家族宏平均 MASE 差异，在 Chronos-2 上为 -0.087 ，95% 区间为 $[-0.284, 0.053]$ ；在 TimesFM 2.5 上为 $+0.052$ ，区间为 $[-0.078, 0.229]$ 。独立块级路由相对于序列级路由的差异分别为 -0.029 $[-0.116, 0.040]$ 和 -0.038 $[-0.120, 0.015]$ 。加入关系图协调后，MASE 仅变化 -0.001 和 -0.003 ，两个区间均跨越零。留一数据族和留出 Sundial 的比较同样未通过预注册优越性判据。另有两项固定检验因预先规定的完整性条件不满足而不可用。在 72 个自然缺失的北京空气质量 episode 上，B-FAIS 相比覆盖全部 episode 的最优固定候选差 0.012 – 0.049 MASE。现有证据未验证预测监督、块级粒度、结构化协调或迁移能力构成一般性贡献。后续研究应以更简单的序列级选择器作为主要参照。

关键词： 时间序列基础模型；缺失值填补；算法选择；下游预测；块级路由；确认性实验

1 引言

时间序列基础模型使跨数据集和跨采样频率的零样本预测成为可行方案。TimesFM 使用仅解码器的分块预测结构 (Das 等 2024)；Chronos 将缩放后的观测映射为离散标记并执行概率预测 (Ansari 等 2024)；Chronos-2 将预训练预测扩展到分组多变量输入 (Ansari 等 2025)。部署时可以冻结这些模型的参数，数值上下文仍会直接决定预测结果。缺失区间会改变局部连续性、季节性证据、变量间关系以及预测器接收的数值范围。

不存在适用于所有缺失条件的单一填补规则。插值依赖局部平滑假设，季节性复制依赖重复结构，多变量补全依赖共享结构，不同神经填补器则学习不同的时间先验 (Buuren 和 Groothuis-Oudshoorn 2011; Stekhoven 和 Bühlmann

2012; Mazumder, Hastie, 和 Tibshirani 2010; Cao 等 2018; Tashiro 等 2021; Du, Côté, 和 Liu 2023; Nie 等 2024)。重建精度与下游预测精度也可能不一致 (Z. Wang 等 2024)。这些事实支持一种条件化算法选择思路：依据受损上下文和冻结预测器，从候选集合中选择填补算法 (Rice 1976; Mısırlı 和 Sebag 2017; Zhao, Rossi, 和 Akoglu 2021; Hazimeh 等 2021; D. Zhou, Li, 和 Gu 2020)。

B-FAIS 面向该问题构建。它将单个变量上的每个极大连续缺失区间表示为缺失块，依据缺失块与 episode 特征预测候选风险，在观测历史上生成伪缺失块以获取候选证据，并求解受原生有效性约束的分配。稀疏关系图和成对风险模型用于协调相邻或相关缺失块上的填补器。该设计包含四项可分离的经验主张：预测损失标签应优于重建标签；块级决策应优于单一序列级决策；基于关系图的协调应优于独立块级选择；训练标签应能迁移到未见数据族，并在更强主张下迁移到未见预测器。

早期版本将这些机制组合为完整系统，并在滚动起点设置下与序列级选择器进行比较 (Tashman 2000)。该结果描述了观测数据集内部的系统行为，尚未区分各机制的独立作用。R2 评估在查看确认性结果前固定研究问题、数据划分、随机种子、统计方法和解释规则。单因素比较阶梯依次包含序列重建、序列预测、独立块预测和结构化块预测。ETT 仅用于开发；确认性评估使用 16 个非 ETT 数据族上的独立掩码；留一数据族训练用于评估未见数据族；Sundial (Liu 等 2025) 不参与教师标签生成和超参数选择。

六项预注册检验均未满足 Holm 校正后的联合优越性规则。四项检验包含全部必需分量，但其区间均跨越零；两项检验因预先规定的可用性条件未满足而不完整。自然缺失空气质量数据进一步给出负向检查。本文据此将贡献界定为：在更严格的实验方案下，对预测感知块级路由的各组成机制进行受控检验；对不可用检验、候选覆盖率和尾部失效提供机器可读证据；明确后续工作应从序列级选择参照出发，并在提出更强机制或迁移主张前补充新证据。

2 相关工作

2.1 预训练时间序列预测

TimesFM 从输入块预测输出块，无需在目标数据集上拟合即可推理 (Das 等 2024)。Chronos 对缩放后的数值进行标记化，并从预训练模型采样未来路径 (Ansari 等 2024)。Chronos-2 使用分组注意力处理多变量输入和协变量信息 (Ansari 等 2025)。Sundial 采用流匹配目标学习连续生成式预测器 (Liu 等 2025)。本研究冻结全部检查点。TimesFM 2.5 与 Sundial 针对每个目标变量独立调用，Chronos-2 接收联合多变量上下文。接口差异可能导致预测器特定的填补行为，因此本文分别报告各预测器结果。

2.2 时间序列填补

经典候选包括链式方程、多变量随机森林补全、低秩补全和时间正则化矩阵分解 (Buuren 和 Groothuis-Oudshoorn 2011; Stekhoven 和 Bühlmann 2012; Mazumder, Hastie, 和 Tibshirani 2010; Yu, Rao, 和 Dhillon 2016)。神经候选包括 BRITS 的双向循环结构 (Cao 等 2018)、GP-VAE 的潜在高斯过程结构 (Fortuin 等 2020)、CSDI 的条件扩散 (Tashiro 等 2021)、SAITS 的自注意力 (Du, Côté, 和 Liu 2023) 和 ImputeFormer 的时空注意力 (Nie 等 2024)。TimeMixer++ 与 TOTEM 等通用时间序列模型也已用于填补评估 (S. Wang 等 2025; Talukder, Yue, 和 Gkioxari 2024)。HELIX 显式建模变量身份与跨维信息 (Zhang 等 2026)。B-FAIS 不改变候选自身目标, 而是通过冻结预测器评估其完整上下文。

2.3 算法选择与下游效用

算法选择将实例描述映射到任务特定性能度量下的候选方法 (Rice 1976)。ALORS 学习任务与算法的潜在因子 (Mısır 和 Sebag 2017); MetaOD 预测潜在任务表征 (Zhao, Rossi, 和 Akoglu 2021); DSelect-k 构建稀疏可微门控 (Hazimeh 等 2021); NeuralUCB 将预测奖励与不确定性结合 (D. Zhou, Li, 和 Gu 2020); HybridLSTM 针对固定长度的单变量窗口推荐填补器 (Almeida 等 2025)。面向任务的填补评估直接考察下游预测后果 (Z. Wang 等 2024)。本文通过单因素阶梯, 分别检验训练目标、决策粒度和分配结构。

3 问题设定

令 $X \in \mathbb{R}^{T \times D}$ 为完整轨迹, $M \in \{0,1\}^{T \times D}$ 为观测掩码。在预测起点 t , 受损上下文与干净未来为

$$C_t = (M \odot X)[t-L:t], \quad Y_t = X[t:t+H, \mathcal{K}],$$

其中, C_t 的缺失项表示为 NaN, $\mathcal{K}$ 为目标变量集合。候选 $a \in \mathcal{A}$ 将 C_t 映射为补全结果 $I_a(C_t)$ 。单独记录的原生有效掩码表示候选在统一数值修复前实际生成的单元格。冻结预测器 f 将有限数值上下文映射为 $\hat{Y}$ 。

对于目标变量 k , MASE 尺度 s_k 由历史拟合前缀及其注册季节滞后 q_k 计算; 季节历史不足时使用滞后一 (Hyndman 和 Koehler 2006)。episode 损失为

$$\mathcal{L}_f(Z, Y) = \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \frac{H^{-1} \sum_{h=1}^H |Y_{h,k} - f(Z)_{h,k}|}{s_k}.$$

单个变量上的每个极大连续缺失区间构成缺失块 $b = (d, s_b, e_b)$ 。块分配 $\mathbf{a} = (a_b)_{b \in \mathcal{B}}$ 通过在缺失块 b 上复制候选 a_b 的输出并恢复观测单元格，得到 $Z(\mathbf{a})$ 。部署阶段在不可访问 Y_t 的条件下选择 $\mathbf{a}$ 。

4 B-FAIS 与受控变体

图 1 将历史监督路径与部署流程分开，并将部署组件与预注册对照对应起来。在历史训练起点，教师用可观测未来评估完整候选上下文的预测损失，并从二阶反事实构造缺失块成对效应。部署时，路由器依次提取极大连续缺失块、生成含安全候选的短名单、利用真实上下文与伪缺失块精炼候选风险，再通过稀疏关系图、原生有效性约束和确定性束搜索完成块级分配。选中的块输出被组装为有限数值上下文并交给冻结预测器。

4.1 预测感知标签与缺失块评分

在历史训练起点，教师评估候选 a 生成的完整上下文：

$$\ell_{e,a}^{\text{full}} = \mathcal{L}_f(I_a(C_e), Y_e).$$

R2 目标审计在 ETT 开发数据族上比较完整候选预测损失、单缺失块反事实损失和协调调整目标，最终选择完整候选预测损失。对于每个采样标注块，将 $\ell_{e,a}^{\text{full}}$ 附着到相应候选行。LambdaMART 排序器 (Burges 2010) 由 LightGBM 实现 (Ke 等 2017)，输入缺失块几何、缺失比例、候选描述和可用上下文特征。监督标签仍为完整上下文结果。部署特征移除数据集身份、数据族身份、缺失生成器身份及生成器目标缺失率。

先验评分器生成至多六个候选的短名单，并强制保留 LOCF 与线性插值作为安全候选。短名单候选在真实上下文和八个从观测历史采样的伪缺失块上运行。精炼 LambdaMART 接收原生覆盖率、重建误差、偏差、输出摘要、缺失块描述和预测器描述。R2 核心配置直接使用学习得到的精炼评分。开发阶段考察的全局候选先验与原始伪误差混合在 ETT 上表现更差，因此不进入确认性评估。候选运行时仅参与短名单构造，分配目标中的运行时权重为零。

4.2 独立块分配与结构化块分配

结构化路由构建稀疏关系图，连接同一变量上的相邻缺失块、时间上重叠的缺失块以及相关变量上的邻近缺失块。Huber 回归器从采样的二阶反事实估计成对交互。结构化能量为

$$E(\mathbf{a}) = \sum_{b \in \mathcal{B}} R(b, a_b) + \beta \sum_{(b,c) \in \mathcal{E}} w_{bc} \hat{\Phi}_{bc}(a_b, a_c), \quad \beta = 1.$$

确定性束搜索宽度为 32。独立块路由分别最小化每个缺失块的一元评分；序列路由则依据某候选在一个 episode 全部缺失块上的平均评分选择一个候选。候选 a 仅在缺失块 b 的全部单元格均为原生有效时才可用于该块。如果短名单内没有有效候选，独立修复状态依次使用线性插值、LOCF 或训练中位数。该修复不会改变候选覆盖率记录。

4.3 单因素比较阶梯

图 1 下方的对照阶梯隔离三项预注册机制变化。序列重建使用掩码上下文重建误差训练序列选择器；序列预测仅将目标替换为完整候选预测损失；独立块预测仅改变决策粒度；结构化块预测进一步加入关系图、成对回归器和协调搜索。最终 B-FAIS 核心对应结构化块预测，并采用 ETT 选择的完整候选目标和纯学习精炼证据。




图 1 B-FAIS 在冻结 TSFM 预测前，将受损多变量上下文转换为受原生有效性约束的块级补全。上部显示历史训练起点如何利用完整候选预测损失和二阶反事实效应训练一元排序器与成对模型；中部以六个编号步骤依次展示缺失块提取、候选短名单、伪缺失证据、风险精炼、联合分配、上下文组装与预测；下部给出预注册机制检验采用的单因素对照阶梯。

5 实验方案

5.1 开发集与确认集

四个 ETT 版本仅用于目标与证据开发。滚动确认集包含 16 个非 ETT 数据族的 26 个数据集版本。每个数据集对每个预测器贡献 90 个 episode，因此每项相邻比较包含 2,340 个配对 episode。上下文长度、预测长度和预测步长均为 96。六种缺失生成器与缺失率 {0.1,0.2,0.3,0.4,0.5} 交叉，确认掩码种子为 {3101,3102,3103}；训练掩码种子为 {1101,1102,1103}；ETT 开发掩码种子为 {2101,2102,2103}。先在完整序列上生成掩码，再切分滚动窗口。2,340 个确认 episode 中有 2,200 个包含上下文缺失，140 个零缺失块窗口保留在固定的全窗口总体中。较早点生成路由器标签，较晚起点用于评估。

5.2 预测器、候选填补器与外部选择器

Chronos-2 和 TimesFM 2.5 分别提供训练标签并接受评估。模型接口具有随机性时，每次预测使用 20 个样本。第三个检查点 thumt/sundial-base-128m 完全留出，不参与标签生成和开发；其无预测器身份路由器移除预测器指示特征。候选注册表包含 20 个条目，其中 19 个可在滚动接口下执行；TRMF 因已安装封装器采用传导式接口而禁用。MetaOD、DSelect-1、NeuralUCB、ALORS、HybridLSTM 和 random-valid 保留以重建为基础的训练目标，不接收下游预测标签。

5.3 迁移与自然缺失

留一数据族（LOFO）训练会移除被评估数据族的全部标注样本、先验和校准值。LOFO 总体包含 17 个数据族，并加入唯一满足条件的 Job Claims 起点，每个预测器共有 2,430 个 episode。留出 Sundial 检验使用共同的 16 数据族总体。自然缺失检验采用 UCI Beijing Multi-Site Air Quality 数据集 (Chen 2017)，包含 12 个站点、11 个数值变量、原生缺失项，以 PM2.5 和 PM10 为目标，共得到 72 个有效滚动 episode；该检验不叠加合成掩码。

5.4 统计方法与判定规则

主要统计量是对各数据族赋予相同权重的家族宏平均 MASE。效应量为配对差异，负值表示表格中首先命名的方法更优。区间使用 5,000 次分层重采样，层级依次覆盖数据族、数据集、样本、起点和掩码。每个分量另做配对的家族级 Wilcoxon 检验。六项固定检验为：H1，预测监督与重建监督；H2，块级路

由与序列级路由；H3，结构化路由与独立块级路由；H4，核心方法与开发阶段选出的外部选择器；H5，LOFO 核心方法与 LOFO 序列方法；H6，Sundial 核心方法同时对比满足可用性阈值的固定填补器和无身份序列选择器。联合检验取所需分量 p 值中的最大值；必需分量不可用时联合 p 值置为 1。六项联合检验统一采用 Holm 校正 (Holm 1979)。优越性要求每个必需区间的上界均小于零且校正后 $p < 0.05$ 。保留路由器种子 4101–4105，预注册主分析使用 4101。

6 结果

6.1 三项拟议机制均未通过确认性检验

表 1 汇总 H1–H3 的六个完整分量。预测监督在两个预测器上的聚合符号相反：Chronos-2 的 MASE 降低 0.087，TimesFM 2.5 的 MASE 增加 0.052，两个区间均包含零。独立块级路由相对于序列级路由在两个预测器上均为负向点估计，但区间上界分别为 0.040 和 0.015。结构化协调导致的家族宏平均 MASE 变化绝对值小于 0.004。所有分量区间均跨越零，三项检验的 Holm 校正值均为 1。

表 1 共同 16 数据族确认集上的相邻机制检验。 Δ 为首先命名的方法减去参照方法的 MASE； p_w 为分量 Wilcoxon 值；联合值为每项检验所需分量的最大值。

检验	对比	预测器	Δ	95% 区间	p_w	联合 p / Holm p
H1	预测 – 重建	Chronos-2	−0.087	[−0.284, 0.053]	0.083	0.744 / 1.000
H1	预测 – 重建	TimesFM 2.5	+0.052	[−0.078, 0.229]	0.744	0.744 / 1.000
H2	块级 – 序列级	Chronos-2	−0.029	[−0.116, 0.040]	0.464	0.464 / 1.000
H2	块级 – 序列级	TimesFM 2.5	−0.038	[−0.120, 0.015]	0.051	0.464 / 1.000
H3	结构化 – 独立	Chronos-2	−0.001	[−0.015, 0.009]	0.464	0.464 / 1.000
H3	结构化 – 独立	TimesFM 2.5	−0.003	[−0.012, 0.003]	0.348	0.464 / 1.000

结构化核心的绝对家族宏平均 MASE 在 Chronos-2 和 TimesFM 2.5 上分别为 7.516 和 2.335；对应的序列预测值为 7.547 和 2.375。五个路由器种子产生相同的核心家族宏平均值，并在报告精度下保存相同分配。这一结果减少了拟合随机性带来的一个不确定来源，但不消除 episode 与数据族差异；后者已由区间表示。

6.2 未见数据族与未见预测器结果仍不确定

LOFO 点估计偏向核心方法，但表 2 中的区间均跨越零。TimesFM 2.5 最接近预注册边界，其区间上界为 +0.0012，分量 $p = 0.080$ 。LOFO 联合检验校正前为 0.378，校正后为 1。对于完全留出的 Sundial，无预测器身份结构化路由相对于无身份序列路由的差异为 -0.016，区间较宽且 $p = 0.940$ 。这些检验未支持未见数据族或跨预测器优越性。

表 2 迁移比较。LOFO 总体包含 17 个数据族；Sundial 使用共同 16 数据族。负值偏向结构化核心。

检验	预测器	配对数	Δ	95% 区间	p_w
H5: LOFO 核心 - 序列	Chronos-2	2,430	-0.018	[-0.107, 0.082]	0.378
H5: LOFO 核心 - 序列	TimesFM 2.5	2,430	-0.077	[-0.192, 0.001]	0.080
H6: 留出核心 - 序列	Sundial	2,340	-0.016	[-0.094, 0.059]	0.940

H4 不可用。预注册 ETT 选择规则要求每个候选外部选择器具有完整主要行。HybridLSTM 对每个受训练预测器均缺少 360 个 ETT episode 中的 100 个，完整性检查据此停止选择，没有命名最强外部方法。H6 也不完整，因为没有固定填补器满足预注册可用性下限。依据固定规则，两项检验的联合值与校正值均为 1。描述性结果显示，核心方法在两个受训练预测器上的共同 16 数据族家族宏平均 MASE 均低于五个可配对外部选择器；Chronos-2 的差异范围为 -4.410 至 -0.376，TimesFM 2.5 为 -3.615 至 -0.464。由于 H4 选择步骤停止，这些描述性结果不能替代确认性 H4 检验。

6.3 自然缺失未恢复所声称优势

表 3 给出 UCI 北京空气质量评估。B-FAIS 覆盖全部 72 个 episode。在三个预测器上，其平均 MASE 均高于同样覆盖全部 72 个 episode 的最优固定候选，差距分别为 0.012、0.049 和 0.029。逐 episode 预言机仍更低，说明候选集合中尚有未利用的选择空间。该单数据族结果属于描述性分析，不构成优越性检验。

表 3 72 个北京空气质量自然缺失 episode 上的评估。最优固定候选仅在覆盖全部 72 个 episode 的候选中选择； Δ 为 B-FAIS 减去该候选。

预测器	B-FAIS	最优完整候选	候选 MASE	Δ	预言机
Chronos-2	1.012	TimeMixer++	1.000	+0.012	0.943
TimesFM 2.5	1.127	多变量 KNN	1.078	+0.049	1.018
Sundial	0.909	TimeMixer++	0.880	+0.029	0.786

7 讨论

受控比较阶梯改变了对 B-FAIS 的解释。H1 未证明预测损失是优于重建损失的训练信号，且两个预测器的效应符号相反，说明不宜将多个时间序列基础模型合并为单一结论。H2 未证明块级粒度优于单一序列决策。H3 的区间最窄且效应接近零，因此关系图、成对回归器和束协调在当前方案下缺少作为性能贡献的证据。依照预注册解释规则，这些机制不进入核心贡献主张。

现有区间也没有建立统计等效性。H1 和 H2 仍允许在部分数据族上存在具有实际意义的效应，TimesFM 的块级路由尤其如此。后续实验可针对造成异质性的特定数据族和缺失几何，先形成固定条件规则，再在新的数据族上评估。当前结果尚不支持任何此类条件规则。因此，更简单的序列级选择器构成可辩护的操作参照，独立块级路由仅保留为实验候选。

不可用检验揭示了比较集设计问题。严格完整性检查防止研究者在查看确认性结果后选择有利方法，维护了预注册判定。若单个方法覆盖不完整，多方法开发比较可能无法提供有效结论。后续方案应在开发评估前分别定义完整案例的主要选择器集合与覆盖率分析，固定填补器的可用性下限也需要同样处理。

自然缺失检验和前缀敏感性进一步限制部署解释。当历史拟合前缀被强制包含缺失值时，家族宏平均变化仍不确定，而最差 episode 的退化在 Chronos-2、TimesFM 2.5 和 Sundial 上分别达到 220.8、44.9 和 39.9 MASE。平均性能可能掩盖严重局部失效。候选有效性、尾部指标和明确的回退评估应继续作为主要输出。

8 局限性

确认性数据采用受控合成掩码。六种生成器和五个缺失率覆盖多类压力条件，但无法表示全部传感器、日志记录或实际运行故障过程。自然缺失研究仅包含一个空气质量数据族和 72 个 episode，在形成部署结论前需要更广泛的自然缺失数据。

主要机制检验使用一个注册路由器种子，尽管五个拟合种子产生相同的核心家族宏平均值。候选神经模型使用仓库统一的十轮训练预算，其他预算可能改变候选排序。TimesFM 2.5 与 Sundial 按目标独立运行，Chronos-2 接收多变量上下文；该差异属于被评估系统的一部分，当前结果未将模型结构与适配器行为分离。

H4 和 H6 的一个必需分量不可用。依据预注册规则得到负向联合判定，同时缺失比较限制了对外部选择器和固定填补器的结论范围。由于开发选择步骤停止，外部选择器差异没有确认性区间。LOFO 从路由器训练中移除被评估数

据族的标签，但仍在每条留出序列的前 20% 上拟合候选填补器。因此，它评估的是未见数据族的路由器迁移，不是严格的零样本候选迁移。

本研究固定候选注册表、96 步上下文与预测长度、六候选短名单以及 20 个预测样本。结果提供经验边界证据，不构成一般不可能性结论。统计等效性与注册的 1% 非劣界限均未作为主要假设检验。

9 结论

本文将预测监督、块级粒度、结构化协调、未见数据族迁移和留出预测器迁移作为 B-FAIS 的独立主张进行检验。六项预注册检验均未满足优越性规则；四项完整检验的区间跨越零，两项检验因预先规定的可用性条件而不完整。自然缺失结果也显示，三个预测器上的当前路由器均落后于覆盖全部 episode 的固定候选。现有证据将 B-FAIS 界定为一个已接受受控检验、但拟议机制尚未获得验证的系统。后续研究应从序列级对照出发，预先定义满足覆盖条件的比较器集合，并将尾部失效作为主要结果。

生成式人工智能使用声明

在本次修订中，作者使用 OpenAI Codex 检查已有源代码和机器可读结果产物，辅助起草与编辑论文文本和表格，核对引文键、数值一致性与文档格式，并协助解释已经生成的实验结果。该工具未生成数据集或本文报告的实验测量值。作者依据源代码和已保存产物复核全部人工智能辅助文本与检查结果，并对论文最终文本、主张和相关产物承担责任。

伦理声明

本研究使用公开发布的数值时间序列数据，并在受控确认数据上添加合成掩码，不涉及干预或人类受试者招募。北京空气质量数据以 CC BY 4.0 发布；其他数据集的所有权和再分发条款仍由各提供方规定。预测误差可能影响能源、劳动力、物流、空气质量和基础设施决策。在缺少领域特定验证、持续监测和回退程序时，不应将该研究系统用于自主运行决策。

可复现性声明

附录 A 记录数据划分、掩码、种子、候选和检查点；附录 C 给出全部确认性分量与敏感性结果；附录 D 将论文主张映射到带版本号的产物与哈希清单。补充源代码树包含本文使用的冻结 YAML 配置、评估代码、测试和机器可读结果摘要。

参考文献

- Almeida, Mauricio Morais, João Dallyson Sousa Almeida, Darlan Bruno Pontes Quintanilha, Geraldo Braz Júnior, 和 Aristófanés Correa Silva. 2025. 《A Meta-Learning Based Neural Network and LSTM for Univariate Time Series Missing Data Imputation》. *Applied Soft Computing* 172: 112845. <https://doi.org/10.1016/j.asoc.2025.112845>.
- Ansari, Abdul Fatir, Oleksandr Shchur, Jaris Küken, Andreas Auer, Boran Han, Pedro Mercado, Syama Sundar Rangapuram, 等. 2025. 《Chronos-2: From Univariate to Universal Forecasting》. *arXiv preprint arXiv:2510.15821*. <https://arxiv.org/abs/2510.15821>.
- Ansari, Abdul Fatir, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, 等. 2024. 《Chronos: Learning the Language of Time Series》. *Transactions on Machine Learning Research*. <https://openreview.net/forum?id=gerNCVqqtR>.
- Burges, Christopher J. C. 2010. 《From RankNet to LambdaRank to LambdaMART: An Overview》. MSR-TR-2010-82. Microsoft Research. <https://www.microsoft.com/en-us/research/publication/from-ranknet-to-lambdarank-to-lambdamart-an-overview/>.
- Buuren, Stef van, 和 Karin Groothuis-Oudshoorn. 2011. 《mice: Multivariate Imputation by Chained Equations in R》. *Journal of Statistical Software* 45 (3): 1–67. <https://doi.org/10.18637/jss.v045.i03>.
- Cao, Wei, Dong Wang, Jian Li, Hao Zhou, Lei Li, 和 Yitan Li. 2018. 《BRITS: Bidirectional Recurrent Imputation for Time Series》. 收入 *Advances in Neural Information Processing Systems*. 卷 31. Curran Associates, Inc. https://papers.nips.cc/paper_files/paper/2018/hash/734e6bfcd358e25ac1db0a4241b95651-Abstract.html.
- Chen, Song. 2017. 《Beijing Multi-Site Air Quality》. UCI Machine Learning Repository. <https://doi.org/10.24432/C5RK5G>.

Das, Abhimanyu, Weihao Kong, Rajat Sen, 和 Yichen Zhou. 2024. 《A Decoder-Only Foundation Model for Time-Series Forecasting》. 收入 *Proceedings of the 41st International Conference on Machine Learning*, 编辑 Ruslan Salakhutdinov, Zico Kolter, Katherine Heller, Adrian Weller, Nuria Oliver, Jonathan Scarlett, 和 Felix Berkenkamp, 235:10148–67. Proceedings of Machine Learning Research. PMLR. <https://proceedings.mlr.press/v235/das24c.html>.

Du, Wenjie, David Côté, 和 Yan Liu. 2023. 《SAITS: Self-Attention-Based Imputation for Time Series》. *Expert Systems with Applications* 219: 119619. <https://doi.org/10.1016/j.eswa.2023.119619>.

Fortuin, Vincent, Dmitry Baranchuk, Gunnar Rätsch, 和 Stephan Mandt. 2020. 《GP-VAE: Deep Probabilistic Time Series Imputation》. 收入 *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics*, 编辑 Silvia Chiappa 和 Roberto Calandra, 108:1651–61. Proceedings of Machine Learning Research. PMLR. <https://proceedings.mlr.press/v108/fortuin20a.html>.

Godahehwa, Rakshitha W., Christoph Bergmeir, Geoffrey I. Webb, Rob J. Hyndman, 和 Pablo Montero-Manso. 2021. 《Monash Time Series Forecasting Archive》. 收入 *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*. 卷 1. https://datasets-benchmarks-proceedings.neurips.cc/paper_files/paper/2021/file/eddea82ad2755b24c4e168c5fc2ebd40-Paper-round2.pdf.

Google Research. 2025. 《TimesFM》. <https://github.com/google-research/timesfm>.

Hazimeh, Hussein, Zhe Zhao, Aakanksha Chowdhery, Maheswaran Sathiamoorthy, Yihua Chen, Rahul Mazumder, Lichan Hong, 和 Ed H. Chi. 2021. 《DSelect-k: Differentiable Selection in the Mixture of Experts with Applications to Multi-Task Learning》. 收入 *Advances in Neural Information Processing Systems*, 34:29335–47. Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2021/file/f5ac21cd0ef1b88e9848571aeb53551a-Paper.pdf.

Holm, Sture. 1979. 《A Simple Sequentially Rejective Multiple Test Procedure》. *Scandinavian Journal of Statistics* 6 (2): 65–70. <https://doi.org/10.2307/4615733>.

Hyndman, Rob J., 和 Anne B. Koehler. 2006. 《Another Look at Measures of Forecast Accuracy》. *International Journal of Forecasting* 22 (4): 679–88. <https://doi.org/10.1016/j.ijforecast.2006.03.001>.

Ke, Guolin, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, 和 Tie-Yan Liu. 2017. 《LightGBM: A Highly Efficient Gradient Boosting Decision Tree》. 收入 *Advances in Neural Information Processing Systems*. 卷 30. Curran Associates, Inc. https://papers.nips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html.

Liu, Yong, Guo Qin, Zhiyuan Shi, Zhi Chen, Caiyin Yang, Xiangdong Huang, Jianmin Wang, 和 Mingsheng Long. 2025. 《Sundial: A Family of Highly Capable Time Series Foundation Models》. 收入 *Proceedings of the 42nd International Conference on Machine Learning*, 267:39295–317. Proceedings of Machine Learning Research. PMLR. <https://proceedings.mlr.press/v267/liu25be.html>.

Mazumder, Rahul, Trevor Hastie, 和 Robert Tibshirani. 2010. 《Spectral Regularization Algorithms for Learning Large Incomplete Matrices》. *Journal of Machine Learning Research* 11 (80): 2287–2322. <https://jmlr.org/papers/v11/mazumder10a.html>.

Mısır, Mustafa, 和 Michèle Sebag. 2017. 《ALORS: An Algorithm Recommender System》. *Artificial Intelligence* 244: 291–314. <https://doi.org/10.1016/j.artint.2016.12.001>.

Nie, Tong, Guoyang Qin, Wei Ma, Yuewen Mei, 和 Jian Sun. 2024. 《ImputeFormer: Low Rankness-Induced Transformers for Generalizable Spatiotemporal Imputation》. 收入 *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2260–71. KDD '24. Association for Computing Machinery. <https://doi.org/10.1145/3637528.3671751>.

Rice, John R. 1976. 《The Algorithm Selection Problem》. 收入 *Advances in Computers*, 15:65–118. Elsevier. [https://doi.org/10.1016/S0065-2458\(08\)60520-3](https://doi.org/10.1016/S0065-2458(08)60520-3).

Rubin, Donald B. 1976. 《Inference and Missing Data》. *Biometrika* 63 (3): 581–92. <https://doi.org/10.1093/biomet/63.3.581>.

Stekhoven, Daniel J., 和 Peter Bühlmann. 2012. 《MissForest—Non-Parametric Missing Value Imputation for Mixed-Type Data》. *Bioinformatics* 28 (1): 112–18. <https://doi.org/10.1093/bioinformatics/btr597>.

Talukder, Sabera J., Yisong Yue, 和 Georgia Gkioxari. 2024. 《TOTEM: TOkenized Time Series EMbeddings for General Time Series Analysis》. *Transactions on Machine Learning Research*. <https://openreview.net/forum?id=QlTLkH6xRC>.

Tashiro, Yusuke, Jiaming Song, Yang Song, 和 Stefano Ermon. 2021. 《CSDI: Conditional Score-Based Diffusion Models for Probabilistic Time Series Imputation》. 收入 *Advances in Neural Information Processing Systems*, 34:24804–16. Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2021/hash/cfe8504bda37b575c70ee1a8276f3486-Abstract.html>.

Tashman, Leonard J. 2000. 《Out-of-Sample Tests of Forecasting Accuracy: An Analysis and Review》. *International Journal of Forecasting* 16 (4): 437–50. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0).

Wang, Shiyu, Jiawei Li, Xiaoming Shi, Zhou Ye, Baichuan Mo, Wenze Lin, Shengtong Ju, Zhixuan Chu, 和 Ming Jin. 2025. 《TimeMixer++: A General Time Series Pattern Machine for Universal Predictive Analysis》. 收入 *The Thirteenth International Conference on Learning Representations*. <https://openreview.net/forum?id=1CLzLXSfNn>.

Wang, Zhixian, Linxiao Yang, Liang Sun, Qingsong Wen, 和 Yi Wang. 2024. 《Task-Oriented Time Series Imputation Evaluation via Generalized Representers》. 收入 *Advances in Neural Information Processing Systems*, 编辑 Amir Globerson, Lester Mackey, Danielle Belgrave, Angela Fan, Ulrich Paquet, Jakub Tomczak, 和 Cheng Zhang, 37:137403–31. Curran Associates, Inc. <https://doi.org/10.52202/079017-4365>.

Yu, Hsiang-Fu, Nikhil Rao, 和 Inderjit S. Dhillon. 2016. 《Temporal Regularized Matrix Factorization for High-Dimensional Time Series Prediction》. 收入 *Advances in Neural Information Processing Systems*. 卷 29. Curran Associates, Inc. https://papers.nips.cc/paper_files/paper/2016/hash/85422afb467e9456013a2a51d4dff702-Abstract.html.

Zhang, Fengming, Wenjie Du, Huan Zhang, Ke Yu, 和 Shen Qu. 2026. 《HELIX: Hybrid Encoding with Learnable Identity and Cross-Dimensional Synthesis for Time Series Imputation》. 收入 *Forty-Third International Conference on Machine Learning*. <https://openreview.net/forum?id=FN20iuPnEU>.

Zhao, Yue, Ryan Rossi, 和 Leman Akoglu. 2021. 《Automatic Unsupervised Outlier Model Selection》. 收入 *Advances in Neural Information Processing Systems*, 34:4489–4502. Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2021/file/23c894276a2c5a16470e6a31f4618d73-Paper.pdf.

Zhou, Dongruo, Lihong Li, 和 Quanquan Gu. 2020. 《Neural Contextual Bandits with UCB-based Exploration》. 收入 *Proceedings of the 37th International Conference on Machine Learning*, 119:11492–502. Proceedings of Machine Learning Research. PMLR. <https://proceedings.mlr.press/v119/zhou20a.html>.

Zhou, Haoyi, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, 和 Wancai Zhang. 2021. 《Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting》. *Proceedings of the AAAI Conference on Artificial Intelligence* 35 (12): 11106–15. <https://doi.org/10.1609/aaai.v35i12.17325>.

附录 A 详细实验方案

A.1 Episode 构造与数据划分

表 A1 记录固定的 R2 episode 方案。每条完整源序列按时间划分。候选填补器仅在前 20% 前缀上拟合；该前缀之后较早的合格起点生成路由器标签，较晚起点形成评估 episode。合成掩码先在完整序列上生成，再切分上下文，因此不同方法共享同一掩码实现，同一起点不会获得有利的重新采样。

表 A1 R2 episode 构造。共同 16 数据族分析和 LOFO 分析均达到数据集上限。

设置	取值
上下文长度 / 预测长度 / 预测步长	96 / 96 / 96
训练窗口步长	24
候选拟合前缀	每条序列的前 20%
预测目标	注册变量 0 和 1
样本 / 训练起点 / 评估起点	至多 4 / 4 / 4
每数据集训练 episode	至多 90
每数据集评估 episode	90
缺失块长度	6、12、24、48
缺失率	0.1、0.2、0.3、0.4、0.5
训练掩码种子	1101、1102、1103
ETT 开发掩码种子	2101、2102、2103
确认掩码种子	3101、3102、3103
路由器种子	4101、4102、4103、4104、4105
全局采样种子	20260806
预测样本数	20
重采样次数 / 种子	5,000 / 20260806

六种生成器分别为随机点缺失、独立块缺失、同步块缺失、交错相关块缺失、数值依赖块缺失，以及独立块与随机点的混合。上述名称描述确定性压力

测试实现，不等同于统计缺失理论中的自然缺失过程 (Rubin 1976)。每个数据集对每个生成器—缺失率—种子单元贡献一个 episode，总数为 $6 \times 5 \times 3 = 90$ 。共同 16 数据族总体对每个预测器包含 2,340 个 episode。140 个零缺失块窗口源于注册全序列掩码的切片，并保留在固定总体中；其余 2,200 个窗口至少包含一个上下文缺失单元格。

A.2 数据集清单

ETT 数据族 (H. Zhou 等 2021) 仅用于开发。Housing Inventory 因仅有 114 个观测，无法同时支持 96 步上下文和 96 步未来而排除。Job Claims 仅有一个合格评估起点，无法与其滚动训练起点分离，因此共同 16 数据族不含该数据；LOFO 将该起点置于留出评估，并加入第 17 个数据族。表 A2 列出共同 16 数据族中的 26 个版本。若干来源收录于 Monash 预测档案 (Godaheewa 等 2021)，各来源条款保留在本地数据清单中。

表 A2 共同 16 数据族确认集与数据集版本；Job Claims 仅加入 LOFO-17。

数据族	数据集版本
Azure 2019	azure2019_D_5T、azure2019_I_5T、azure2019_U_5T
Coastal TS	Coastal_T_S_15T、Coastal_T_S_20T、Coastal_T_S_H
Current velocity	current_velocity_5T、current_velocity_15T、 current_velocity_20T、current_velocity_H
Electricity	electricity
EWELD load	EWELD_Load_15T
Exchange rate	exchange_rate
JOLTS	JOLTS_M
National illness	national_illness
NE China wind	NE_China_Wind_H
OpenElectricity NEM	OpenElectricity_NEM_5T
Port activity	Port_Activity_D、Port_Activity_W
Supply chain	Supply_Chain_Customer_D、Supply_Chain_Location_D
Traffic	traffic
Uncertainty	Uncertainty_1M_M

数据族	数据集版本
US labor	US_Labor_M
Vehicle	Vehicle_Sales_M、Vehicle_Supply_M
LOFO 单独加入	Job_Claims_W

A.3 候选注册表与原生有效性

注册表包含 20 个条目。TRMF 被禁用，因为已安装的 PyPOTS 1.5 封装器采用传导式接口，与滚动拟合和推理不兼容。其余 19 个候选经统一的拟合与填补接口执行。统一数值修复前检查候选输出；修复后的数值可以保证预测器输入有限，但不会改变候选的原生有效状态。

表 A3 实际执行的填补候选。

分组	候选
时间规则	LOCF、线性插值、季节滞后
状态空间与高斯过程	Kalman local trend、Kalman AR、STL-Kalman、GP-RBF
多变量统计	KNN、MICE、MissForest、SoftImpute
专用神经网络	BRITS、GP-VAE、SAITS、CSDI、ImputeFormer、HELIX
通用时间序列模型	TimeMixer++、TOTEM

短名单始终包含 LOCF 和线性插值，再按预测风险降低量与实测执行成本之比加入至多四个候选。短名单构造是唯一启用的计算代价惩罚，分配代价系数为零。深度候选统一训练十轮，批量大小为 16，并使用仓库内适配器；CSDI 生成五个填补样本。这些预算保证实验可复现，不表示每个候选可达到的最优精度。

A.4 预测器接口

TimesFM 适配器使用 `google/timesfm-2.5-200m-pytorch` (Google Research 2025)，并独立预测每个目标。Chronos-2 使用 `amazon/chronos-2` (Ansari 等 2025)，接收联合多变量上下文，以预测中位数计算点预测 MASE。Sundial 使用 `thuml/sundial-base-128m`，固定快照为 `3212e42564493f520593e5414af4367fc4b49226`，并独立预测每个目标。Sundial 不提供教师标签，也不参与 ETT 开发。

附录 B 方法与对照细节

B.1 训练目标

教师为每个候选行保存三类预测目标。完整候选损失评估完全由单一候选填补的上下文；单缺失块损失在共同锚点中仅替换一个缺失块；协调调整目标加入采样的交互信息。单独的重建标签采用掩码上下文绝对对称百分比误差，仅供序列重建和外部序列选择器使用。

表 B1 给出在 ETT 开发数据上选择完整候选损失的结果。这些数值是开发均值，不具有独立数据族重复，只用于配置选择，不进入确认性主张。纯学习证据行采用精炼排序器评分；注册混合还加入原始伪误差代理和历史候选先验。表 B1 ETT 开发决策。MASE 越低越优；纯学习减混合的差异越负越优。本表不作确认性推断。

排序器目标	Chronos-2	TimesFM 2.5	综合
完整候选预测损失	1.456	1.643	1.550
单缺失块预测损失	1.534	1.721	1.628
协调调整目标	1.763	1.706	1.735
纯学习 - 注册混合	-0.0348	-0.0135	—

对于选定目标，完整候选损失会重复附着到与采样缺失块关联的候选行。排序器可以依赖缺失块特征，标签本身仍评估完整候选补全。该细节关系到 H2 的解释：块级选择器改变分配粒度，没有引入局部观测的缺失块标签。

B.2 特征策略

部署可用策略移除 dataset_id::*、family_id::*、missing_mechanism::* 和生成器给出的目标缺失率；从可见上下文计算的局部与全局缺失比例仍可用。无预测器身份策略进一步移除 forecast_model::*。候选身份和候选家族仍然保留，因为选择器必须区分候选。表 B2 列出保留的特征组。

表 B2 路由器特征组。所有量均可从训练历史、受损上下文、候选元数据或候选输出获得。

特征组	示例
缺失块几何	变量、起止位置、长度、相对位置、边界可用性、局部缺失比例
Episode 上下文	可见缺失比例、变量数、季节周期、训练前缀摘要
候选描述	候选和家族身份、拟合范围、尾部/周期能力、随机标志、设备与实测代价

特征组	示例
伪缺失证据	原生覆盖率、MAE、RMSE、偏差、不确定性、输出摘要、匹配的伪块几何
成对描述	边类型与权重、重叠或间隔、相关性、块对几何、候选对、输出摘要
预测器描述	预测器身份、上下文模式、目标粒度、输出类型；无身份迁移时移除

B.3 关系图、成对标签与求解器

同一变量上的相邻缺失块获得随间隔衰减的边。跨变量缺失块在时间范围重叠或接触时连接；拟合前缀中相关的变量，其邻近缺失块也可以连接。度数上限用于避免同步点缺失形成稠密图。成对标签采用二阶反事实差异：

$$\Phi_{bc}(a, a') = \mathcal{L}_f(A^{b \leftarrow a, c \leftarrow a'}, Y) - \mathcal{L}_f(A^{b \leftarrow a}, Y) - \mathcal{L}_f(A^{c \leftarrow a'}, Y) + \mathcal{L}_f(A, Y),$$

其中 A 为共同完整锚点。每个教师 episode 至多采样四个缺失块、六个候选和四个成对标签。结构化推理使用宽度 32 的束搜索；缺失块数超过 512 时省略成对项。独立块推理选择每个缺失块上的有效最小值。序列推理要求单个候选对全部缺失块有效，并选择平均一元评分最低者。

B.4 外部选择器适配

外部方法保留序列级决策单元与基于重建的目标。MetaOD 预测潜在任务表征；ALORS 学习任务—候选协同因子；DSelect-1 使用一个稀疏专家门；NeuralUCB 使用上下文赌博机评分；random-valid 从对完整 episode 有效的候选中均匀采样；HybridLSTM 使用固定 48 步单变量窗口和其方法专用候选池。由于 HybridLSTM 在部分窗口上没有有效输出，结果单独报告覆盖率。精确超参数冻结在 [configs/iclr27-r2/baseline-selectors/](https://github.com/google-research/google-research/blob/master/iclr27-r2/baseline-selectors/)。

附录 C 完整确认性与敏感性结果

C.1 六项固定检验

表 C1 给出全局多重检验集合。H1、H2、H3 和 H5 包含全部必需分量；H4 与 H6 依据注册可用性规则不完整。所有 Holm 校正值均为 1，没有任何检验满足优越性陈述条件。

表 C1 六项全局检验判定表。必需分量不可用时，联合原始值置为 1。

检验	联合原始 p	Holm p	完整	可作优越性判定
H1: 预测与重建	0.743561	1.000	是	否
H2: 块级与序列级	0.463745	1.000	是	否
H3: 结构化与独立	0.463745	1.000	是	否
H4: 核心与选定外部方法	1.000000	1.000	否	否
H5: LOFO 核心与序列	0.377823	1.000	是	否
H6: Sundial 迁移	1.000000	1.000	否	否

H4 的 ETT 开发选择覆盖六个注册外部方法。HybridLSTM 在 Chronos-2 的 360 个主要 episode 中产生 100 个不合格 episode，TimesFM 2.5 同样为 100 个。注册规则 `missing_duplicate_ineligible_or_nonfinite_primary_row_stops_decision` 因此停止评分，将选定方法保留为空值。H6 的固定候选分支没有找到满足可用性下限的候选。这些结果按不可用分量保留，没有在查看确认性结果后改用其他比较。

C.2 完整分量的尾部行为

表 C2 报告每个可用固定检验分量的配对 episode 退化。由于大量候选分配相同，所有行的中位数均为零。H1、H2、H5 和 H6 的正向上尾仍较大；H3 的尾部差异最小，与结构化分配和独立分配几乎一致相符。

表 C2 被检方法减参照方法的 MASE 尾部统计。变差率为配对差异大于零的比例。

检验	预测器	对比	CVaR90	CVaR95	最大值	变差率
H1	Chronos-2	预测 – 重建	1.834	3.089	44.872	33.1%
H1	TimesFM 2.5	预测 – 重建	1.586	2.710	44.219	30.5%
H2	Chronos-2	块级 – 序列级	0.901	1.555	29.616	34.4%
H2	TimesFM 2.5	块级 – 序列级	0.479	0.798	5.009	24.4%
H3	Chronos-2	结构化 – 独立	0.133	0.262	6.579	11.6%

检验	预测器	对比	CVaR90	CVaR95	最大值	变差率
H3	TimesFM 2.5	结构化 – 独立	0.024	0.047	0.927	4.2%
H5	Chronos-2	LOFO 核心 – 序列	1.384	2.412	46.320	31.5%
H5	TimesFM 2.5	LOFO 核心 – 序列	0.684	1.085	5.088	27.2%
H6	Sundial	留出核心 – 序列	0.596	1.056	55.286	24.1%

C.3 外部选择器描述性比较

表 C3 给出核心方法减可配对外部序列选择器的家族宏平均差异。共同 16 数据族列包含 2,340 个配对 episode 和 16 个数据族；LOFO 包含 2,430 个 episode 和 17 个数据族。由于 H4 选择停止，这些行没有确认性区间。HybridLSTM 在共同 16 数据族上仅有 1,745 个合格 episode，在 LOFO 上有 1,884 个，未达到完整覆盖。

表 C3 与外部序列选择器的描述性家族宏平均差异。负值偏向 B-FAIS 核心；C、T、S 分别表示 Chronos-2、TimesFM 2.5 和 Sundial。

方法	共同 C	共同 T	共同 S	LOFO C	LOFO T
MetaOD	−0.376	−0.464	−0.540	−0.121	−0.256
DSelect-1	−4.410	−3.615	−4.600	−1.998	−2.564
NeuralUCB	−0.462	−0.586	−0.717	−0.858	−0.549
ALORS	−1.718	−1.236	−1.101	−0.824	−0.803
Random-valid	−2.320	−1.429	−1.986	−3.239	−2.586
HybridLSTM	不可用	不可用	不可用	不可用	不可用

C.4 路由器种子核验

五个滚动路由器种子均具有不同的模型哈希与摘要哈希。种子 4101–4105 得到的核心家族宏平均 MASE 在报告精度下完全相同：Chronos-2 为 7.516111，TimesFM 2.5 为 2.334864。主要固定检验按注册使用种子 4101。随机种子进入两个 LambdaMART 模型和成对回归器，不仅体现在输出目录名称中。

C.5 不完整前缀敏感性

主要合成实验在完整的前 20% 前缀上拟合候选模型。敏感性运行以 10% 缺失率破坏该前缀，并保证没有完整训练窗口。表 C4 按计划 episode 身份和独立

掩码实现，将该运行与标准前缀核心比较。家族宏平均区间跨越零，但 episode 上尾显著扩大。

表 C4 无完整前缀减标准前缀的敏感性结果，共 2,340 个配对 episode 和 16 个数据族。

预测器	家族 Δ	95% 区间	CVaR95	最大值	变差率
Chronos-2	+0.078	[-0.055, 0.396]	6.171	220.815	43.0%
TimesFM 2.5	+0.018	[-0.075, 0.136]	2.243	44.895	37.9%
Sundial	+0.023	[-0.079, 0.141]	1.878	39.890	37.8%

C.6 自然缺失细节

每个北京 episode 至少包含一个原生缺口。平均上下文缺失比例为 3.33%，范围为 0.09%–26.99%。表 C5 增补 B-FAIS 的分布统计。预言机在每个 episode 上选取 MASE 最低的原生有效候选，仅用于诊断。

表 C5 72 个自然缺失 episode 上 B-FAIS 的 MASE 分布。

预测器	均值	中位数	P95	CVaR95	预言机均值
Chronos-2	1.012	1.087	1.776	1.953	0.943
TimesFM 2.5	1.127	1.152	2.114	2.498	1.018
Sundial	0.909	0.937	1.660	1.695	0.786

附录 D 产物完整性与可复现性

D.1 产物映射

最终完整性报告状态为 VERIFIED。表 D1 将论文证据映射到仓库相对路径；同时存在 JSON 与 CSV 时均予以保留。

表 D1 主要机器可读证据文件。

证据	仓库相对路径
完整性报告	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/report.md
六项检验判定	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/global_holm_tests.csv
固定检验分量	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/global_holm_components.csv
外部方法描述	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/external_selector_comparisons.csv
证据开发	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/evidence_ablation_comparisons.csv
前缀敏感性	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/prefix_sensitivity_comparisons.csv
自然缺失	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/uci_native_missing_summary.csv

证据	仓库相对路径
五种子核验	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/common16_five_seed_verification.json
H4 选择停止	artifacts/iclr27-r2/r2-external-ett-development-selection-stopped-ms2101x3-rs4101-v005/selection.json
资源摘要	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/resource_summary.json
源文件与依赖哈希	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/source_and_dependency_signatures.json
完整产物清单	artifacts/iclr27-r2/r2-final-analysis-integrity-v007/artifact_manifest.json

H4 选择停止文件包含停止规则、不合格数量、源文件哈希和空选定方法，是解释 H4 所需的证据。

D.2 资源统计

R2 产物树包含 210 次记录运行和 84 个评估清单。84 项评估均完整；19 个调度器状态记录失败或中断尝试，这些尝试从结果摘要中排除。已完成清单记录 145,639 次预测器调用，共处理 2,669,387 个预测上下文。记录的最大 CUDA 已分配内存为 1,088,912,384 字节，最大保留内存为 1,166,016,512 字节。累计记录时长为 245.1 小时，其中流水线运行时间为 81.8 小时，预测调用内部时间为 9.6 小时。不同阶段的运行性质不同，上述累计值不代表单次端到端基准。

D.3 历史结果隔离与软件检查

R2 输出仅位于 artifacts/iclr27-r2/。隔离审计共清点 40,678 个历史文件，没有发现 R2 启动时间之后写入的历史文件。本文任何表格均未混合历史数值与 R2 数值。

当前源代码修订通过 526 项自动化测试。Ruff 检查通过，mypy 对 61 个源文件检查成功；测试套件产生一个预期的 MICE 收敛警告。这些检查验证单因素对照配置、掩码分区隔离、特征移除、原生有效性、路由元数据和产物签名等实现约束。科学假设仍由前述结果表判定。

D.4 复现范围

源代码树包含冻结配置、注册表、路由与评估代码、结果摘要和测试。精确重运行还需要清单引用的本地原始数据、填补器检查点和预测器快照。评估阶段不会静默下载替代预测器。分配完成后恢复观测上下文值，候选资格在回退修复前测量；改变任一规则都会改变覆盖率，并可能改变配对总体。

资源清单记录 Windows、Python 3.10、PyTorch 2.5.1、CUDA 12.4、随机种子、解析后的配置和输入哈希。原始数据再分发应遵守各提供方条款；UCI 北京数据采用 CC BY 4.0 (Chen 2017)。